

Fundamentos de Análisis de Series Temporales en R

Nerys Ramírez Mordán

Universidad Autónoma de Santo Domingo
Pontificia Universidad Católica Madre y Maestra
info.nerysramirez@gmail.com - Data Science | DR

Marzo 2019

Tabla de contenido

- 1 Econometría?
- 2 Series temporales: aspectos básicos
- 3 Box-Jenkins
- 4 Modelos de volatilidad
- 5 Análisis multivariado
- 6 Modelos multivariados de volatilidad
- 7 Métodos bayesianos
- 8 Referencias

Econometría?

Econometría?

- Se ocupa de la medición de las relaciones entre las variables económicas y la confrontación de la teoría con evidencia empírica (Stewart y Wallis, 1984).

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Econometría?

- **1914.** Modelos de demanda y ciclos económicos.
- **1930.** creación de la Econometric Society.
- **1950.** MC2E (Theil, 1954); VI (Sargan, 1958), modelos estructurales.
- **1960.** Fundamentos microeconómicos.
- **1970.** Variable dependiente cualitativa (McFadden, 1974); Logit (Amemiya, 1978); Probit (Albright, et al., 1977); datos de panel; Box-Jenkins (1978); Critica de Lucas (Lucas, 1972); relaciones espúreas (Granger y Newbold, 1974).

Econometría?

- **1980.** VAR (Sims, 1980). Cointegración (Granger, 1981); Raíz Unitaria (Dickey-Fuller, 1979); MCE (Sargent, 1984); ARCH (Engel, 1982); GARCH (Bollerslev, 1986); VAR inferencia (Runkle, 1987).
- **2000.** Suavización exponencial (Yelland and Lee, 2003), VAR con restricciones de signos (Uhlig, 2004).

Series temporales: aspectos básicos

Aspectos básicos

- $\{y_t\}$: es una secuencia de variables aleatorias indexadas en el tiempo ($t \in [1, 2, \dots, T]$):

$$Y_t = y_1, y_2, \dots, y_T$$

- Su **realización** ($Y(\omega)$) una posible trayectoria del proceso.
- **Proceso estocástico**: familia de variables aleatorias $\{Y_t$
 $t \in T\}$, definido en un espacio de probabilidad discreto
 $\{t = 1, 2, \dots\}$ o continuo.

Aspectos básicos

- Los **momentos** de un proceso se obtienen a partir de las propiedades de sus distribuciones marginales:
 - $E[Y_t] = \mu_t, \quad t = 1, 2, 3, \dots, T$
 - $V[Y_t] = E[Y_t - \mu_t]^2 = \sigma_t^2, \quad t = 1, 2, 3, \dots, T$
 - $Cov[Y_t, Y_s] = E[(Y_t - \mu_t)(Y_s - \mu_t)]$

Aspectos básicos

- Las **distribuciones condicionales** a k valores anteriores, conociendo $y_{t-1}, y_{t-2}, \dots, y_{t-k}$.
- **Proceso markoviano:** $(y_{t+1} | y_t, y_{t+1-1}, \dots, y_1) = f(y_t)$.

Aspectos básicos

- Basados en el teorema central del límite y la ley de grandes números de Kolmogorov (Soto, 2010):

$$\bar{x}_n = \frac{1}{N} \sum_{i=1}^n x_i \rightarrow \mu$$

- Ahora, $\{y_t\}$ (no n secuencias) incluye **dependencia temporal** que impide se apliquen los análisis tradicionales (Shumway y Stoffer, p.1).

$$\bar{x}_t = \frac{1}{T} \sum_{i=1}^T x_i \rightarrow \mu$$

Aspectos básicos

- $\{y_t\}$ es *estrictamente estacionaria* cuando la función de distribución de $(Y_t, Y_{t+1}, Y_{t+2}, \dots, Y_{t+k})$ es idéntica a $(Y_\tau, Y_{\tau+1}, Y_{\tau+2}, \dots, Y_{\tau+k}) \forall \tau, t$ y k .
- El proceso y_t es *estacionario en covarianzas* si $\mu_t = E[Y_t] = \mu$ y $\gamma_{t,k} = \gamma_k, \forall t$ y k (Lutkepohl and Kratzig, 2004, p.12).
- Un proceso *estacionario de orden k* , es aquel donde la probabilidad en t_1, t_2, t_m , es igual a la de $t_{1+k}, t_{2+k}, t_{m+k}$.

Aspectos básicos

- $Y_t = \varepsilon_t$ es un proceso **ruido blanco** ($\varepsilon_t \sim iid(0, \sigma^2)$), sí:

$$E[y_t] = 0; \quad E[y_t y_s] = \begin{cases} \sigma^2 & \forall s = t \\ 0 & \forall s \neq t \end{cases}$$

- Solo si $Y_t = \varepsilon_t$, se justifica totalmente la utilización de *momentos muestrales* para caracterizar y_t (Novales, 2016a, p.3).

Aspectos básicos

- Cuando $E[y_t y_s] \neq 0 \forall s \neq t$ se requiere un modelo (Novales, 2016a, p.3).
- El **operador de retardo** (L , lags), retrasa los elementos de una secuencia un periodo $Ly_t = y_{t-1}$, $L^2 y_t = y_{t-2}$, de forma que $Ly_t = y_{t-1}$ (L^{-i} es el **operador de adelantos**).

$$(1 + \beta_1 L + \beta_2 L^2)x_t = x_t + \beta_1 x_{t-1} + \beta_2 x_{t-2}$$

Aspectos básicos

- $\{Y_t\} \sim AR$: $\phi(L)y_t = \varepsilon_t$, siendo ε_t la innovación del proceso, y $\phi(L) = (1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p)$ el **polinomio autoregresivo**.

$$y_t = \phi_1 y_{t-1} - \phi_2 y_{t-2} - \dots - \phi_p y_{t-p} + \varepsilon_t$$

- Si $\{Y_t\} \sim AR(1)$ y $\phi_1 = |1|$, el proceso es no estacionario y se conoce como una **caminata aleatoria**.

Aspectos básicos

- $\{Y_t\} \sim Ma$: $y_t = \theta(L)\varepsilon_t$, siendo ε_t la innovación del proceso, y $\theta(L) = (1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_p L^p)$ el **polinomio de media móvil**.

$$y_t = \phi_1 \varepsilon_{t-1} - \phi_2 \varepsilon_{t-2} - \dots - \phi_p \varepsilon_{t-p} + \varepsilon_t$$

Aspectos básicos

- El **ARMA** es:

$$\phi(B) y_t = \theta(B) \varepsilon_t \quad \varepsilon_t \sim RB(0, \sigma^2)$$

- El **ARMA** con $E[y_t] \neq 0$, es:

$$\phi(B) y_t = c + \theta(B) \varepsilon_t \quad \varepsilon_t \sim RB(E[y_t], \sigma^2)$$

Aspectos básicos

- Dado un **proceso integrado** de orden d ($y_t \sim I(d)$, si $\Delta_d y_t \sim I(0)$), el **ARIMA** es:

$$\phi(B)(1-L)^d y_t = \theta(B)\varepsilon_t \quad \varepsilon_t \sim RB(0, \sigma^2)$$

- $\Delta^d (= (1-L)^d)$ es el **operador de diferencias**:
 $\Delta y_t = (1-L)y_t = y_t - y_{t-1}$
 $\Delta^2 y_t = (y_t - y_{t-1}) - (y_{t-1} - y_{t-2})$

Aspectos básicos

- Sea $\{y\}_{t=1}^T$ una serie temporal, se puede descomponer aditiva o multiplicativamente, según sus componentes:

$$\begin{aligned}y_t &= T_t + C_t + S_t + I_t \\y_t &= T_t * C_t * S_t * I_t\end{aligned}\tag{1}$$

- T_t tendencia.
- S_t Componente estacional.
- C_t Ciclo.
- I_t Componente irregular o innovación.

Aspectos básicos

- La presencia de elementos estacionales, se incorporan al modelo ARIMA (**SARIMA**), aplicando el **operador de diferencia estacional** $\Delta_s y_t = (1 - L^s)x_t = y_t - y_{t-s}$:

$$\phi(B) \Phi(B^s) (1 - B)^d (1 - B^s)^D y_t = \theta(B) \Theta(B^s) \epsilon_t$$

- El SARIMA, considera diferencias estacionales, siendo D el orden de integración estacional de $\{y\}_{t=1}^T$:

$$y_t - y_{t-s} = (1 - L^s)^D y_t$$

Aspectos básicos

- Los modelos **RegARIMA**, son modelos de regresión cuyos errores siguen un modelo SARIMA $(x_t - x'\beta)$:

$$\phi(B) \Phi(B^s) (1-B)^d (1-B^s)^D (y_t - y'\beta) = \theta(B) \Theta(B^s) \epsilon_t$$

- El modelo de $\{y\}_{t=1}^T$, viene dado por:

$$Y_t = \beta_0 + \sum_{j=1}^k \beta_j t^j + \sum_{j=1}^s \sigma_j I_j(t) + \epsilon_t$$

Box-Jenkins

Box-Jenkins

- Paso 1. Verificar estacionariedad.
 - La transformación de Box-Cox (1964), permite estabilizar la varianza, siendo λ el parámetro de transformación:

$$y_t^\lambda = \begin{cases} \frac{x_t^\lambda - 1}{\lambda}, & \text{si } \lambda \neq 0 \\ \ln(y_t), & \text{si } \lambda = 0 \end{cases}$$

- $\lambda = 1 - \alpha$, que se obtiene de estimar $\ln h_t = c + \alpha \ln \bar{y}_t$,
 $\bar{y} = (y_1, y_2, \dots, y_n)^{\frac{1}{n}}$ es la media geométrica móvil y h_t es la desviación móvil.

Box-Jenkins

- Paso 1. Verificar estacionariedad.
 - La función de **autocorrelación simple** de orden k entre y_t y y_{t+k} .

$$r_k = \frac{\sum_{t=1}^{T-k} (y_t - \bar{y})(y_{t+k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2} = \frac{\gamma_k}{\gamma_0} \sim N(0, 1/T)$$

- La función de **autocorrelación parcial** entre x_t y x_{t-k} , a partir del modelo autorregresivo es:
$$x_t = \beta_0 + \alpha_1 x_{t-1} + \dots + \alpha_k x_{t-k} + u_t.$$

$$a_k = \text{Corr}(x_t, x_{t-k} | x_{t-1}, \dots, x_{t-k+1})$$

Box-Jenkins

- Paso 1. Verificar estacionariedad.
 - La prueba **Dickey-Fuller** supone $y_t \sim AR(1)$ para testear estacionariedad en diferencia ($\alpha_1 = \rho_1 - 1$), utilizando:

$$\begin{aligned}\Delta y_t &= \alpha_1 y_{t-1} + u_t \\ \Delta y_t &= \phi_0 + \alpha_1 y_{t-1} + u_t \\ \Delta y_t &= \phi_0 + \phi_1 t + \alpha_1 y_{t-1} + u_t\end{aligned}$$

- $h_0 : \alpha_1 = 0$, estadístico $t = \frac{\hat{\alpha}_1}{de(\alpha_1)}$.

Box-Jenkins

- Paso 1. Verificar estacionariedad.
 - El test **Dickey-Fuller Aumentado** (ADF):

$$\Delta y_t = \phi_0 + \phi_1 y_{t-1} + \sum_{i=2}^p \phi_i \Delta y_{t-i} + \varepsilon_t$$

- El test **Phillip-Perron** corrige el estadístico del DF, por la posible autocorrelación y heterocedasticidad en ε_t .

Box-Jenkins

- Paso 2. Identificación del proceso.
 - ① Correlogramas.
 - ② Criterios de información:

$$AIC = \ln \hat{\sigma}^2 + 2\frac{k}{T}$$

- ③ Análisis residual a partir de los test Box, que testea, $\forall h$
 $h_0 : \rho_{(h)} = 0$ y $h_a : \rho_{(h)} \neq 0$

Box-Jenkins

- Paso 3. Estimación.
 - Para un ARMA(p,q) con $\Theta = (\mu, \phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q)'$, el vector (p+q+1)-dimensional de parámetros, se puede obtener a partir de la función de verosimilitud:

$$\mathbf{L}(\Theta, \sigma_w^2) = \prod_{t=1}^T f(y_t | y_{t-1}, \dots, y_1)$$

En el caso de un $AR(1) \sim i.i.d.N(0, \sigma^2)$:

$$f(y_1; \theta) = \frac{1}{\sqrt{2\pi\sigma^2/(1-\phi^2)}} \exp \left\{ -\frac{[y_1 - c/(1-\phi)]^2}{2\sigma^2/(1-\phi^2)} \right\}$$

Box-Jenkins

- Paso 4. Validación.
 - Además de los correlogramas, el test de *Box* testea, $\forall h$ $h_0 : \rho_{(h)} = 0$ y $h_a : \rho_{(h)} \neq 0$, utilizando el estadístico de prueba **Box-Pierce** (1970):

$$Q_h = T \sum_{k=1}^h \hat{\rho}_{\varepsilon,k}^2 \sim \chi_h^2$$

- Test **Ljung-Box** (1978):

$$Q_h = T(T+2) \sum_{k=1}^h \frac{\rho_{\varepsilon,k}^2}{T-k} \sim \chi_h^2$$

Box-Jenkins

- Paso 4. Pronósticos.
 - Predecir valores futuros de y_{t+m} , $m = 1, 2, \dots$, basados en la información conocida hoy (\mathbf{y}).

$$y_{t+m} = \mathbf{E}(y_{t+m}|\mathbf{y})$$

- Esta media condicional mín $\mathbf{E}[(y_{t+m} - g(\mathbf{y}))^2]$ a partir de $\{y_1, \dots, y_n\}$, el pronóstico a un paso seria:

$$y_{t+1} = \phi_1 y_t + \phi_2 y_{t-1} + \dots$$

Box-Jenkins en R

```
1 #Declarar el objeto
2 Px <-ts(x,frequency =252, start =c(1991,04))
3 plot(Px,type="l")
4
5 dx<-diff(log(Px))
6
7 par(mfrow=c(1,2))
8 plot(dx,type="l")
9 acf(dx)
```

Box-Jenkins en R

```
1 # Paso 1. Estacionariedad (Test Dickey Fuller)
2 library(urca)
3 mod<-ur.df(dx,type =c("none"),lags =0)
4 summary(mod)
5
6 ur.df(dx, type =c("none"), lags =1,
7 +      selectlags ="AIC")
```


Box-Jenkins en R

```
1 # Paso 2. Identificar el proceso
2 # A partir del criterio de informacion
3 mod1<-arima(dx, order =c(1,0,0))
4 mod2<-arima(dx, order =c(0,0,1))
5 mod3<-arima(dx, order =c(1,0,1))
6 mod4<-arima(dx, order =c(2,0,0))
7
8 AIC(mod1, mod2, mod3, mod4)[,2]
```

Box-Jenkins en R

```
1 # Paso 2. Identificar el proceso
2 # Correlogramas
3 par(mfrow=c(1,2))
4 acf(dx,xlim=c(1,20),main="acf")
5 pacf(dx,xlim=c(1,20),main="pacf")
6
7 # Coeficientes en tablas
8 acf(d1oro,plot=FALSE)$acf[2:11]
```

Box-Jenkins en R

```
1 # Paso 2. Identificar el proceso
2 # An lisis de los residuos
3 r<-mod1$residuals
4
5 # Test de Box
6 Box.test(r,lag =1,type ="Box-Pierce")
7 Box.test(r,lag =1,type ="Ljung-Box")
8
9 # Normalidad
10 qqnorm(r)
11 qqline(r,col =2)
```

Box-Jenkins en R

```
1 # Paso 3. Estimar el proceso
2 mod1<-arima(dx,order =c(1,0,0))
3 print(mod1)
4
5 # Paso 4. Validar
6 library(tseries)
7
8 library(forecast)
9 tsdiag(mod1)
```

Box-Jenkins en R

```
1 # Paso 5. Usar el modelo
2 library(forecast)
3 mod1<-arima(x,order =c(1,1,1))
4
5 fcast <-forecast(mod1,h=10)
6 plot(fcast)
7 plot(forecast(mod1,fan=TRUE))
8
9 # Valores pronosticados e IC
10 fcast
```

Box-Jenkins en R

```
1 # Componentes de una serie temporal
2 fit <- decompose(x, type = 'multiplicative')
3 autoplot(fit)
4
5 # Serie ajustada
6 xAjustada <- x-fit$seasonal-fit$trend
```

Box-Jenkins en R

```
1 # SARIMA
2 auto.arima(xAjustada,seasonal=FALSE)
3 auto.arima(x,seasonal=T)
4
5 mod1 <-arima(x, order=c(3,1,2),
6 +           seasonal=c(1,0,1))
7 mod1
```

Box-Jenkins en R

```
1 # RegARIMA
2 datos <- data.frame(x, meses=months(dates))
3
4 # Dummies estacionales
5 datos$dummyS <- factor(datos$meses)
6 dummyS2 <- model.matrix(~datos$dummyS - 1)
7
8 # [, -1]?
9 fit <- arima(x, xreg=dummyS2[, -1],
10 +           order=c(1, 1, 0))
11 print(fit)
```


Modelos de volatilidad

Modelos de volatilidad

- $y_t(\theta) \sim \mathbf{ARCH}$, si su esperanza sigue el proceso:

$$E_{t-1}[y_t(\theta)] = 0 \quad \forall t = 1, 2, \dots$$

y su varianza condicional:

$$h_t^2(\theta_0) = \text{Var}_{t-1}[y_t(\theta)] = E_{t-1}[y_t^2(\theta)] = g(y_{t-1}, y_{t-2}, \dots)$$

Modelos de volatilidad

- El **modelo EWMA** es un modelo de suavización exponencial, con λ como parámetro de suavización:

$$\sigma_t^2 = \lambda_1 \sigma_{t-1}^2 + (1 - \lambda) y_{t-1}^2$$

Modelos de volatilidad

- El **ARCH** es un modelo discreto, que condiciona la varianza en t , a la información pasada, $var(y_t|\Omega_{t-1}) = \sigma_t^2$, siendo su especificación $ARCH(p)$:

$$\sigma_t^2 = \alpha_1 y_{t-1}^2 + \alpha_2 y_{t-2}^2 + \cdots + \alpha_p y_{t-p}^2 = \sum_{i=1}^p \alpha_i y_{t-i}^2$$

Modelos de volatilidad

- El **test ARCH** parte de la estimación MCO del $AR(p)$:

$$\epsilon_t^2 = \alpha_0 + \alpha_1 \epsilon_{t-1}^2 + \alpha_2 \epsilon_{t-2}^2 + \dots + \alpha_p \epsilon_{t-p}^2 + v_t$$

- Para testear $h_0 : \alpha_i = 0, \forall i = 1, 2, \dots, p$, usando el estadístico $T * R^2 \sim \chi_p^2$.

Modelos de volatilidad

- El **GARCH(p,q)** modeliza la volatilidad condicional a partir de dos ecuaciones:

$$\begin{aligned} y_t &= \epsilon_t h_t \\ \sigma_t^2 &= \omega + \sum_{i=1}^q \alpha_i u_{t-i}^2 + \sum_{i=1}^p \beta_i \sigma_{t-i}^2 + \epsilon_{t-1} \end{aligned}$$

- Cuya estimación se determina a partir de un MLE.

$$\mathbb{L} = \prod_{t=1}^T \left[\frac{1}{\sqrt{2\pi\sigma_t^2}} e^{-\frac{\epsilon_t^2}{2\sigma_t^2}} \right]$$

Modelos de volatilidad

- Glosten, Jagannathan y Runkle (**GJR**, 1993), propusieron modelar la asimetría en la respuesta de la volatilidad a shocks pasados:

$$\sigma_t^2 = \omega + \sum_{i=1}^q \left[\alpha_1 \varepsilon_{t-i}^2 + \lambda_1 1_{(\varepsilon_{t-i} \leq 0)} \varepsilon_{t-i}^2 \right] + \sum_{i=1}^p \beta_1 \sigma_{t-i}^2 + \varepsilon_{t-1}$$

Modelos de volatilidad

- Asumiendo media cero y ausencia de autocorrelación, el modelo **Markov-GARCH** se representa como:

$$y_t | (s_t = k, F_{t-1}) \sim \mathbb{D}(0, h_{k,t}, \xi_k)$$

- s_t es definida en $\{1, 2, \dots, k\}$, según una matriz cadena markov homogénea y ergódica de primer, con $\mathbb{P} = \{P_{i,j}\}_{i,j=1}^k$:

$$p_{i,j} = \Pr[s_t = j | s_{t-1} = i]$$

Modelos de volatilidad

- $E[y^2|s_t = k, F_{t-1}] = h_{k,t}$, que según Haas et al. (2004), queda en función de los retornos pasados y el vector de parámetros dependientes del régimen:

$$h_{k,t} = h(y_{t-1}, h_{k,t-1}, \theta_k)$$

$$h_{k,t} = \omega_k + \alpha_k y_{t-1}^2 + \beta_k h_{k,t-1}$$

Modelos de volatilidad

- La extensión asimétrica incluye el efecto apalancamiento:

$$h_{k,t} = \omega_k + [\alpha_k + \gamma_k I\{y_{t-1} < 0\}]y_{t-1}^2 + \beta_k h_{k,t-1}$$

Modelos de volatilidad

- Los modelos de **volatilidad estocástica** (Taylor, 1980), consideran la volatilidad como una variable latente no observable, con choques no lineales (!mle).
- EL ARSV(1):

$$y_t = \sigma * \sigma_{tt}$$
$$\log \sigma_t^2 = \phi \log \sigma_{t-1}^2 + \sigma_h (1 - \phi^2) \varepsilon_t$$

Modelos de volatilidad en R

```
1 # Test ARCH
2 # Histogramas
3 par(mfrow=c(1,2))
4 hist(dx,probability =TRUE)
5 hist(dx^2,probability =TRUE)
6
7 # Correlogramas
8 par(mfrow=c(1,2))
9 acf(dx^2,20,ylim=c(-0.05,0.2),col='red')
10 pacf(dx^2,20,col='red')
```

Modelos de volatilidad en R

```
1 #Test ARCH
2 #by hand
3 mod1<-arima(dx, order =c(1,0,0))
4 e<-mod1$residuals
5 arima(e^2, order =c(1,0,0))
6
7 # Auto. alternative: heteroscedastic
8 library(aTSA)
9 arch.test(mod1, output =TRUE)
```

Modelos de volatilidad en R

```
1 #GARCH
2 library(fGarch)
3 fit =garchFit(~garch(1,1), data =dx)
4
5 options(scipen=999)
6 summary(fit)
7
8 # contrastar su validez.
9 res =residuals(fit, standardize =T)
10 par(mfrow=c(1,2))
11 acf(res, 20)
12 pacf(res, 20)
```

Modelos de volatilidad en R

```
1 #GARCH, serie de volatilidad
2 volatility <- volatility(fit,type ="sigma")
3 plot(volatility,type='l')
```

Modelos de volatilidad en R

```
1 #ARIMA - GARCH
2 fitARMAGARCH <- garchFit( ~arma(1,1)+garch(1,1),
3                             data =dx)
4 summary(fitARMAGARCH )
5
6 # GARCH Asimetrico
7 fitARMAgjrGARCH <-garchFit( ~arma(1,1)+garch(1,1),
8                             leverage =TRUE, data =dx)
```


Modelos de volatilidad en R

```
1 # Alternativa
2 library(parallel); library(rugarch)
3 spec =ugarchspec(variance.model =
4                   list(model ="gjrGARCH"))
5
6 fit =ugarchfit(spec =spec, data =dx)
7 show(fit)
8
9 # GARCH no gaussianos
10 # "dnorm", "dged", "dstd"
11 spec =ugarchspec(variance.model =
12                   list(model ="gjrGARCH"),
13                   distribution.model ="std")
```

Modelos de volatilidad en R

```
1 # Markov-GARCH
2 # MS(2)-GARCH(1,1)- Student
3 spec <- CreateSpec(
4   variance.spec = list(model = c("gjrGARCH")),
5   distribution.spec =
6     list(distribution = c("std")),
7   switch.spec = list(K = 2))
8
9 # fit the model on the data with ML estimation
10 fit <- FitML(spec = spec, data = dlnX)
11 summary(fit)
```

Análisis multivariado

Análisis multivariado

- Decimos que un vector n-dimesional de variables aleatorias Y_t ($Y_t' = [Y_{1t}, \dots, Y_{nt}]$) es *estacionario en covarianza* si: $E(Y_t) = \mu$, y Σ es independiente del tiempo ($E(Y_t - \mu)(Y_{t-j} - \mu)'$).
- El concepto de **dependencia débil**, establece una restricción sobre la relación entre las variables.

$$\text{cov}[Y_t, Y_{t-k}] \xrightarrow{k \rightarrow \infty} 0 \quad (2)$$

Análisis multivariado

- El **VAR(p)** es una transformación del modelo estructural (sin considerar exógenas), dado los problemas de simultaneidad:

$$By_t = \Gamma_0 + \Gamma_1 y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(M, \Sigma_\varepsilon)$$

- Siendo $Y_t = [y_{1,t}, y_{2,t}, \dots, y_{k,t}]' \sim I(0)$, y:

$$B = \begin{pmatrix} 1 & -\alpha_{11} \\ -\alpha_{21} & 1 \end{pmatrix}; \Gamma_0 = \begin{pmatrix} \alpha_{10} \\ \alpha_{20} \end{pmatrix}; \Gamma_1 = \begin{pmatrix} \alpha_{12} & \alpha_{13} \\ \alpha_{22} & \alpha_{23} \end{pmatrix}$$

Análisis multivariado

- Premultiplicamos el modelo estructural transformado por B^{-1} , donde se encuentran las restricciones estructurales o las relaciones contemporáneas entre variables, para obtener la representación del VAR:

$$Y_t = B^{-1}\Gamma_0 + B^{-1}\Gamma_1 Y_{t-1} + B^{-1}\varepsilon_t$$

$$Y_t = A_0 + A_1 Y_{t-p} + u_t$$

Análisis multivariado

- La forma matricial de un $VAR_2(1)$:

$$\begin{bmatrix} 1 & -b_{11} \\ -b_{21} & 1 \end{bmatrix} \begin{bmatrix} y_t \\ z_t \end{bmatrix} = \begin{bmatrix} b_{10} \\ b_{20} \end{bmatrix} + \begin{bmatrix} b_{12} & b_{13} \\ b_{22} & b_{23} \end{bmatrix} \begin{bmatrix} y_{t-1} \\ z_{t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{yt} \\ \varepsilon_{zt} \end{bmatrix}$$

- Ahora, premultiplicamos por B^{-1} ,

$$\begin{bmatrix} y_t \\ z_t \end{bmatrix} = B^{-1} \begin{bmatrix} b_{10} \\ b_{20} \end{bmatrix} + B^{-1} \begin{bmatrix} b_{12} & b_{13} \\ b_{22} & b_{23} \end{bmatrix} \begin{bmatrix} y_{t-1} \\ z_{t-1} \end{bmatrix} + B^{-1} \begin{bmatrix} \varepsilon_{yt} \\ \varepsilon_{zt} \end{bmatrix}$$

$$B = \begin{bmatrix} 1 & -b_{11} \\ -b_{21} & 1 \end{bmatrix}; B^{-1} = \frac{1}{1 - b_{11}b_{21}} \begin{bmatrix} 1 & b_{11} \\ b_{21} & 1 \end{bmatrix}$$

Análisis multivariado

- Ahora, verifique que $u_t = B^{-1}\epsilon_t$ son combinaciones lineales de las innovaciones estructurales de interés.

$$y_t = (B^{-1}\Gamma_0) + (B^{-1}\Gamma_1)y_{t-1} + B^{-1}\epsilon_t \quad (3)$$

- El VAR es una **forma reducida** (sistema de ecuaciones en que cada variable endógena se expresa en función solo de las variables predeterminadas) derivada de algún modelo estructural (Londoño, 2005, p.5).

Análisis multivariado

- El orden del VAR(**p**), se obtiene a partir del *análisis residual* o por los *criterios de información*.

$$AIC = \ln |\Omega| + 2 \frac{(n^2 p + n)}{T}$$

$$BIC = \ln |\Omega| + 2 \frac{(n^2 p + n) \ln(T)}{T}$$

Análisis multivariado

- Tomando la representación *ma* del VAR, siempre que este sea invertible:

$$Y_t = \mu + \sum_{i=0}^{\infty} A_1^i u_{t-i}$$

- A_1^i de orden $k \times k$, es la **función impulso respuesta** al horizonte i , o reacción al sistema a un hipotético vector de *shocks* $\delta = \delta_1, \delta_2, \dots, \delta_i$ a las innovaciones $(u_{1t}, u_{2t}, \dots, u_{it})$.

Análisis multivariado

- El problema de identificación parte de que:

$$y_t = (\mathbf{B}^{-1}\Gamma_0) + (\mathbf{B}^{-1}\Gamma_1)y_{t-1} + \mathbf{B}^{-1}\epsilon_t$$

- Los choques estructurales ($\epsilon_t = Bu_t \sim iid(0, B\Sigma_u B')$).
Donde \mathbf{B} es una matriz cuadrada, triangular inferior con $(k^2 - k)/2$ restricciones.

$$\Sigma = \begin{bmatrix} \sigma_y^2 & \sigma_{zy} \\ \sigma_{yz} & \sigma_z^2 \end{bmatrix}$$

Análisis multivariado

- El VAR modelo VAR:

$$Y_t = A_0 + A_1 Y_{t-p} + u_t$$

Donde,

$$E \left[u_t u_t' \right] = \Sigma_t$$

$$u_t = \mathbf{B}^{-1} \epsilon_t$$

$$\text{Con } E \left[\epsilon_t \epsilon_t' \right] = I \text{ con } E \left[\epsilon_t \epsilon_{t-k}' \right] = 0 \quad \forall k = 1, 2, 3, \dots$$

Análisis multivariado

- Los choques estructurales son una transformación lineal del viejo vector de errores $u_t = \mathbf{B}^{-1}\epsilon_t$.
- u_t es una función de varios choques.

Análisis multivariado

- Existen distintas estrategias para recuperar (identificar) los *shocks* originales (Ramírez, F., 2017):
 - 1 Recursiva: descomposición de Cholesky.
 - 2 VAR estructural
 - Restricciones de corto plazo
 - Restricciones de largo plazo
 - Restricciones de signos;
 - Estudios de eventos.

Análisis multivariado

- La *fir* considera los *shocks* ocurren en una sola variable, supuesto viable únicamente en condiciones de independencia.
- La descomposición de **Cholesky** permite obtener innovaciones ortogonales mediante una identificación recursiva.

Análisis multivariado

- **B** se puede obtener de $\Sigma = BB'$, mediante la (descomposición de Cholesky), donde B es una matriz triangular inferior ($(k^2 - k)/2$ restricciones):

$$\Sigma = \begin{bmatrix} \sigma_y^2 & \sigma_{zy} \\ \sigma_{yz} & \sigma_z^2 \end{bmatrix} = \begin{bmatrix} a & 0 \\ b & c \end{bmatrix} \begin{bmatrix} a & b \\ 0 & c \end{bmatrix}$$

Análisis multivariado

- Como $u_t = \mathbf{B}^{-1}\epsilon_t$, recursivamente se puede obtener el efecto de los choques estructurales:

$$\epsilon_t = \mathbf{B}u_t$$

En el caso del $VAR_2(p)$:

$$\begin{vmatrix} \epsilon_t^{y_{1,t}} \\ \epsilon_t^{y_{2,t}} \end{vmatrix} = \begin{vmatrix} 1 & 0 \\ b_{21} & 1 \end{vmatrix} \begin{vmatrix} u_t^{y_{1,t}} \\ u_t^{y_{2,t}} \end{vmatrix}$$

Análisis multivariado

- $y_{1,t}$ es independiente a choques contemporáneos en $y_{2,t}$, pero $y_{2,t}$ si se ve afectada por choques en $y_{1,t}$, por lo que, el orden de las variables sigue el nivel de exógeneidad.

Análisis multivariado

- El test de **causalidad de Granger**, asume $Y_t \sim VAR(2)$:

$$y_t = \mu + A_1 Y_{t-1} + A_2 Y_{t-2} + \varepsilon_t$$

- Por lo que, el mejor pronóstico, basado en el medelo lineal:

$$\hat{y}_{t+1} = \mu + A_1 Y_t + A_2 Y_{t-1}$$

- Iterativamente:

$$\hat{y}_{t+k} = \mu + A_1 \hat{y}_{t+k-1} + A_2 \hat{y}_{t+k-2}$$

Análisis multivariado

- Asumiendo el modelo:

$$y_t = c_1 + a_1 y_{t-1} + a_2 y_{t-2} + b_1 x_t + b_2 x_{t-2} + u_{y,t}$$

- El test, contrasta la $H_0 : b_1 = b_2 = 0$ (x_t no causa a y_{x_t}), frente a: $H_a : b_i \neq 0, \forall i \in (1, 2)$.

Análisis multivariado

- Un conjunto de variables se dice son **cointegradas**, si existe una combinación lineal que genere un vector estocástico estacionario (Catalán, nd).

$$y_t - \beta_1 x_{1,t} - \beta_2 x_{2,t} - \dots - \beta_k x_{k,t} = \mathbf{u}_t \sim I(0) \quad (4)$$

Análisis multivariado

- Formalmente, sean las variables $x_t \sim I(1)$ y $y_t \sim I(1)$, están **cointegradas** si existe una combinación lineal $(y_t - \alpha - \beta x_t)$ de esas series que sea estacionaria de orden $I(0)$ (Novales, 2016).
- Entonces, se dice que las variables x_t e y_t , tal que $I(d)$, están cointegradas si $u_t \sim I(d-1)$.

Análisis multivariado

- El **MCE** propone que la dinámica de **corto plazo** de las variables, está influenciada por las desviaciones del equilibrio ($\hat{u} = 0$) (desequilibrio = $\hat{u} = y_{t-1} - \hat{\beta}_0 - \hat{\beta}_1 x_{t-1}$).

$$\Delta y_y = \alpha_0 + \alpha_1 \Delta x_t + \alpha_2 \Delta y_{t-1} + \alpha_3 \hat{u}_{t-1} + \epsilon_t$$

$$\Delta y_y = \alpha_0 + \alpha_1 \Delta x_t + \alpha_2 \Delta y_{t-1} + \alpha_3 (y_t - \hat{y}_{t-1}) + \epsilon_t$$

Análisis multivariado

- El MCE (Engle y Granger, 1987) intenta juntar el comportamiento de largo plazo con el de corto plazo. Asumiendo una relación estable de largo plazo, pero con desequilibrios en el corto plazo.
- Conciliando el enfoque Box-Jenkins –que omitía las relaciones de largo plazo– con modelos basados en teoría económica que presentaban problemas asociados con regresiones espurias.

Análisis multivariado

- El **VCEM**, parte de la relación:

$$Y_t = \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + u_t$$

- Podemos restar Y_{t-1} de ambos lados:

$$\begin{aligned} Y_t - Y_{t-1} &= \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + u_t - Y_{t-1} \\ \Delta Y_t &= (\beta_1 - I) Y_{t-1} + \beta_2 Y_{t-2} + u_t \end{aligned}$$

- Sabiendo que $Y_{t-2} = \Delta Y_{t-1} + Y_{t-1}$

$$\begin{aligned} \Delta Y_t &= (\beta_1 - I) Y_t + \beta_2 (\Delta Y_{t-1} + Y_{t-1}) + u_t \\ \Delta Y_t &= (\beta_2 + \beta_1 - I) Y_t + \beta_2 \Delta Y_{t-1} + u_t \end{aligned}$$

Análisis multivariado

- Siendo $(\beta_2 + \beta_1 - I) = \Pi$ y $\beta_2 = \Gamma$, obtenemos la representación tradicional del **VCEM**:

$$\Delta Y_t = \Pi Y_t + \Gamma \Delta Y_{t-1} + u_t$$

- Π es una matriz cuadrada de **largo plazo** conocida como el termino de corrección de error. Mientras, Γ representa la dinámica de **corto plazo**, libres de restricciones.

Análisis multivariado

- En el caso de un sistema autoregresivo bivariado de orden p , con series $I(1)$:

$$y_t = \sum_{j=1}^p \gamma_{1j} \Delta x_{t-j} + \sum_{j=1}^p \gamma_{2j} \Delta y_{t-j} + \epsilon_{1t}$$

- A partir del teorema de representación de Granger (1983):

$$\Delta y_t = \alpha_1 (y_{t-1} - \beta x_{t-1}) + \sum_{j=1}^{p-1} \gamma_{1j}^* \Delta x_{t-j} + \sum_{j=1}^{p-1} \delta_{1j}^* \Delta y_{t-j} + \epsilon_{1t}$$

Análisis multivariado

- El enfoque **Johansen** de cointegración, utiliza r (el rango de Π , igual al número de valores propios (λ) distintos de cero), para determinar las relaciones de cointegración:
 - Cuando $r(\Pi) = 0$ todas las variables tienen raíces unitarias $\ln(1 - \lambda_i) = 0$.
 - Cuando $r(\Pi) = n$ todas las variables son estacionarias.
 - Cuando $(0 < r(\Pi) < n)$, el rango determina el número de relaciones de cointegración.

Análisis multivariado

- Empíricamente, se utiliza el test secuencial del rango de Π para contrastar cointegración, en el conocido **test de la traza**, que utiliza como estadístico de prueba:

$$\lambda_{trace}(m) = -T \sum_{i=r+1}^n \ln(1 - \hat{\lambda}_i) \quad (5)$$

- La hipótesis nula es de no cointegración, $H_0 : r(\Pi) \leq m$ vs. $H_a : r(\Pi) > m$.

Análisis multivariado

- Esta secuencia del test se repite hasta que h_0 no se rechace:
 - Primera prueba: $H_0 : r(\Pi) = 0$ y $H_a : r(\Pi) = 1$.
 - Segunda prueba: $H_0 : r(\Pi) \leq 1$ y $H_a : r(\Pi) = 2$.
 - ...
 - k-ésima prueba: $H_0 : r(\Pi) \leq k - 1$ y $H_a : r(\Pi) = k$.

Análisis multivariado

- Los **modelos factoriales** lineales intentan determinar efectos causales a partir de un reducido número de factores:

$$Y_t = \alpha_i + \sum_{i=1}^k \beta_i X_j^f + \epsilon_i$$

Análisis multivariado en R

```
1 # Orden VAR
2 library(vars)
3 VARselect(data, lag.max = 6, type = "both")
4
5 # Estimación
6 varest <- VAR(data, p = 2)
7 varest
8
9 # Podemos seleccionar el retardo directamente
10 varest <- VAR(data, lag.max = 5, ic = "AIC")
```


Análisis multivariado en R

```
1 # Validar VAR
2 acf(residuals(varest)[,1])
3
4 #h0 = no serial correlation
5 serial.test(varest, lags.pt =16,
6             type ="PT.asymptotic")
7
8 #stability
9 plot(stability(varest), nc =2)
```

Análisis multivariado en R

```
1 # Impulse response analysis
2 varirfs <- irf(varest, n.ahead = 48)
3 plot(varirfs)
4
5 # Bootstrap CI
6 var.irf <- irf(varest, response = "X1",
7               n.ahead = 48, boot = TRUE,
8               ci = 0.95, runs = 100)
9 plot(var.irf)
```

Análisis multivariado en R

```
1 # Impulse response analysis
2 var.irf <- irf(varest,
3               response = "X1",
4               impulse = "X2",
5               cumulative = T,
6               n.ahead = 48,
7               boot = TRUE,
8               ci = 0.95,
9               runs = 100)
10
11 plot(var.irf)
```

Análisis multivariado en R

```
1 # Descomposición de la varianza
2 fevd.svar <- fevd(varest, n.ahead = 5)
3 fevd.svar
```

Análisis multivariado en R

```
1 # Causalidad
2 library(lmtest)
3 grangertest(X1~X2, order =3)
4
5 # Pronóstico
6 VARforecast <- predict(varest, n.ahead =4)
7 VARforecast
```

Análisis multivariado en R

```
1 # VAR estructurales
2 Amat <-diag(3)
3 Amat[1:3,1:3] <-NA
4 diag(Amat)<-1
5
6 Bmat <-diag(3)
7 Bmat[2,1] <-Bmat[3,1] <-Bmat[3,2] <-NA
8 Bmat[!upper.tri(Bmat,-1)] <-NA
9
10 svar.ShortRun <-SVAR(varest,
11                       estmethod ="scoring",
12                       Bmat =VCMatrix,
13                       Amat =Bmat,
14                       max.iter =200)
15
16 summary(svar.ShortRun)
```

Análisis multivariado en R

```
1 # VAR estructurales (IFR)
2 irf.ShortRun <- irf(svar.ShortRun,
3                     impulse = "X1",
4                     response = "X2",
5                     boot = FALSE)
6
7 plot(irf.ShortRun)
8
9 # Descomposición de la varianza
10 fevd.svarb <- fevd(svar.ShortRun, n.ahead = 5)
11 fevd.svarb
```

Análisis multivariado en R

```
1 #Estimaci n de modelos VECM
2 library(tsDyn)
3
4 # Box Trans
5 lamb.prod.elec <-BoxCox.lambda(prod.elec)
6 prod.elec.a <-BoxCox(prod.elec,
7                      lambda=lamb.prod.elec)
```


Análisis multivariado en R

```
1 #Enfoque de cointegración Engle y Granger
2 modelCoint <-lm(prod.elec~prod.ind)
3 resid<-modelCoint$residuals
4 adf.test(resid,k=5)
```

Análisis multivariado en R

```
1 #Test de cointegración autovalores propios
2 sjd.vecm <-ca.jo(X, ecdet ="const",
3                 type="eigen",
4                 K=2,
5                 spec="longrun")
6 sjd.vecm
7
8 # T calculado Vs. T Critico
9 c(sjd.vecm@teststat[1], sjd.vecm@teststat[2])
10 sjd.vecm@cval
```

Análisis multivariado en R

```
1 #Selección de rezagos
2 matrixVarSelect<-VARselect(X, lag.max=6)
3 lags<-matrixVarSelect$selection[1]
4
5 #Estimación del VECM
6 vecm <-VECM(X, lag=lags,
7             r=1,
8             estim="2OLS",
9             include=c("const"))
```

Análisis multivariado en R

```
1 #Pronóstico VECM  
2 predict(vecm,n.ahead=10)
```

Modelos multivariados de volatilidad

Modelos multivariados de volatilidad

- La relación (regresión) entre pares de volatilidades, permite estudiar la asociación y **transferencia de volatilidades** entre series (Novales, 2015).

$$\sigma^2_{(y.t)} = \beta_1 + \beta_2 \sigma^2_{(x.t)} + v_t$$

Modelos multivariados de volatilidad

- La representación multivariante del GARCH(q,p), se obtiene a partir de la representación VEC:

$$VEC(\Sigma_t) = C + \sum_{i=1}^q a_i \cdot VEC(\varepsilon_{t-1} \varepsilon'_{t-1}) + \sum_{j=1}^p b_{ji} \cdot VEC(\Sigma_{t-1})$$

- La versión diagonal $A = \text{diag}[\text{vec}(a)]$ y $B = \text{diag}[\text{vec}(b)]$.

Modelos multivariados de volatilidad

- El modelo BEKK:

$$\Sigma_t = C_0 C_0' + \sum_{k=1}^K \sum_{i=1}^q \mathbf{A}_{ki}' \varepsilon_{t-1} \varepsilon_{t-1}' \mathbf{A}_{ki} + \sum_{k=1}^K \sum_{i=1}^p \mathbf{B}_{ki}' \Sigma_{t-1} \mathbf{B}_{ki}$$

- Siendo C_0 una matriz triangular de orden inferior, \mathbf{A} y \mathbf{B} , son matrices de parámetros $n \times n$.

Modelos multivariados de volatilidad

- Bollerslev (1990) sugirió Modelo de correlación condicional constante (CCC), donde $\sigma_{ij,t}$ solo depende de $\sigma_{ii,t}$ y $\sigma_{jj,t}$:

$$\begin{aligned}\sigma_{ii,t} &= c_i + \sum_{h=1}^p a_{hi} \varepsilon_{t-h,i}^2 + \sum_{h=1}^q b_{hi} \sigma_{t-h,i} \quad i = 1, 2, \dots, k \\ \sigma_{ij,t} &= \rho_{ij} \cdot \sqrt{\sigma_{i,t} \sigma_{j,t}} \\ \rho_{ij} &= \rho_t = \rho\end{aligned}$$

Modelos multivariados de volatilidad

- Tse and Tsui (2002) proponen el modelo Dynamic Conditional Correlation Model (DCC):

$$\rho_t = (1 - \theta_1 - \theta_2) \rho + \theta_1 \psi_{t-1} + \theta_2 \rho_{t-1}$$

- θ_1 y θ_2 son escalares, ψ_{t-1} es la matriz de correlaciones muestrales de $e_{it} = \frac{\varepsilon_{it}}{\sqrt{\sigma_{ii,t}}}$. Si $\theta_1 = 0$ y $\theta_2 = 0$ se obtiene el CCC.

Modelos m. de volatilidad en R

```
1 library(rmgarch); library(rugarch); library(parallel)
2
3 l <- 2 #numero de variables
4 gjrtspec <- ugarchspec(
5     mean.model=list(armaOrder=c(0,0)),
6     variance.model =list(model = "gjrGARCH"),
7     distribution="std")
8
9 dcc_spec = dccspec(
10     uspec = multispec(replicate(l, gjrtspec))
11     distribution = "mvt")
12
13 # Fit DCC
14 garchdccfit = dccfit(dcc_spec, data1,
15     fit.control=list(scale=TRUE))
```

Modelos m. de volatilidad en R

```
1 # distintos modelos por variable
2 uspec1 = ugarchspec(
3     mean.model = list(armaOrder = c(1,0)),
4     variance.model = list(model = "apARCH"),
5     distribution.model = "norm")
6
7 uspec2 = ugarchspec(
8     mean.model = list(armaOrder = c(2,0)),
9     variance.model = list(model = "gjrgARCH"),
10    distribution.model = "norm")
11
12 uspec = c(uspec1, uspec2)
13 spec = dccspec(uspec = multispec(uspec),
14    dccOrder = c(1,1),
15    distribution = "mvlaplace")
16
17 garchdccfit = dccfit(spec, data1,
18    fit.control=list(scale=TRUE))
```

Modelos m. de volatilidad en R

```
1 # Parametros
2 print(garchdccfit)
3 plot(garchdccfit)
4
5 # Matriz Var-Cov en t (Array(k,k,T))
6 dcccov<-rcov(garchdccfit)
7
8 # Matrix de Corr
9 dcccor<-rcor(garchdccfit)
```

Modelos m. de volatilidad en R

```
1 # Extrae elementos de las matrices
2 vol1<-c()
3 T<-1000
4 for (i in 1:T){
5   vol1<-c(vol1, dcccov[1,1,i]) #dcccov[1,1,:]
6 }
7
8 plot(vol1,type="l")
```

Modelos m. de volatilidad en R

```
1 # MGARCH-BEKK
2 library(mgarchBEKK)
3 estimated <- BEKK(data1)
4
5 estimated$est.params
6 estimated$asy.se.coef
7
8 estimated$cor[[1]][[2]]
9 estimated$sd[[1]]
10 estimated$uncond.cov.matrix
11
12 estimated$aic
13 estimated$order
```

Modelos m. de volatilidad en R

```
1 # MGARCH - mGJR.rBEKK
2 estimated1 <- mGJR(x,y)
3
4 estimated1$est.params
5 estimated1$asy.se.coef
6
7 estimated1$cor
8 estimated1$sd1
9 estimated1$sd2
10 estimated1$uncond.cov.matrix
11
12 estimated1$resid1
```


Métodos bayesianos

Métodos bayesianos

- Los **modelos lineales dinámicos** introducen dinámica en los estimadores, al considerarlos $f(t)$ en la ecuación de estado:

$$y_t = x_t' \beta_t + \varepsilon_t$$
$$\beta_t = G\beta_{t-1} + \omega_t$$

Referencias

Referencias I

1. Adhikari, R. Agrawal, R. *An Introductory Study on Time Series Modeling and Forecasting*.
2. Alexios Ghalanos (2015). *rmgarch: Multivariate GARCH models*. R package version 1.2-9.
3. Dickey, D.A. y W.A. Fuller (1979). *Distribution of the Estimators for Autoregressive Time Series With a Unit Root*. Journal of the American Statistical Association. vol. 74, pp. 427-431.
4. Dwyer, G. (2015). *The Johansen Tests for Cointegration*.
5. Enders, W. *Applied Econometric Time Series*. University of Alabama.
6. Gambetti, Lucas (2016). *Empirical Time Series Methods for Macroeconomic Analysis*. Universitat Autònoma de Barcelona and Barcelona GSE.
7. Johansen, S. (2012). *The analysis of nonstationary time series using regression, correlation and cointegration*. University of Copenhagen and CREATES University of Aarhus, Denmark.
8. Lutkepohl, Helmut and Kratzig, Markus (2004). *Applied time series econometrics*. Cambridge University.
9. Novales, Alfonso (2016). *Series temporales*. Universidad Complutense de Madrid.

Referencias II

10. Novales, Alfonso (2016a). *Series temporales. Estacionariedad, raíces unitarias*. Universidad Complutense de Madrid.
11. Novales, Alfonso (2015). *Midiendo la volatilidad en los mercados financieros*. Universidad Complutense de Madrid.
12. Petris, Giovanni (2010). *An R Package for Dynamic Linear Models*. University of Arkansas. Journal of Statistical Software.
13. Pfaf, Bernhard and Taunus, Kronberg (2008). *VAR, SVAR and SVEC Models: Implementation Within R Package vars*.
14. Soto, Raimundo (2010). *Econometría de series temporales*. Pontificia Universidad de Chile.
15. Tsay, R. *Analysis of Financial Time Series*. Second edition. University of Chicago. Graduate School of Business
16. Ramírez, Francisco (2017). *Análisis Multivariado de Series de Tiempo*.
17. Shumway, R. and Stoffer, D. (2011). *Time Series Analysis and Its Applications. With R Examples*. Springer New York Dordrecht Heidelberg London. Third edition.
18. Schmidbauer, Harald; Roesch, Angi and Sinan, Vehbi (2016). *Simulating, Estimating and Diagnosing MGARCH (BEKK and mGJR) Processes*.

Referencias III

19. Watson, Mark and Stock, Jame (2019). *Time Series Econometrics*. AEA 2019 Continuing Education: Time Series Econometrics.